Hoja de estudio

Segmentación de lesiones FDG en PET/CT: todo lo que tengo que saber explicar

BME423, mini-proyecto. Sebastián Inostroza. Cada término tiene la definición en simple, a veces una comparación, y qué valor o rol tiene en el proyecto.

Lo que tengo que poder decir sin mirar

1. El FDG marca consumo de glucosa, no cáncer. Por eso un umbral confunde órganos normales con tumor.
2. Datos: autoPET, 251 estudios, 176 entrenamiento, 26 validación, 49 prueba, por paciente.
3. Comparo tres formas de juntar PET y CT: A temprana, B dos codificadores con concatenación, C con atención cruzada. E agrega el SUV referido al hígado.
4. Hipótesis: la atención cruzada baja el falso positivo sin subir el falso negativo.
5. Resultado: las cuatro empatan (Dice^{+} 0,61 a 0,64). Ningún intervalo de confianza excluye el cero.
6. Contra el umbral clásico: FPV 1 192 mL contra unos 21 mL, 57 veces menos. 74 % del error clásico estaba en órganos fisiológicos.
7. La atención de C está muerta: con $\gamma = 0$ la predicción no cambia ni un vóxel. La normalización de instancia borra su salida, que es casi constante.
8. Detectan prácticamente todo sobre 10 mL y una de cada cinco lesiones bajo 1 mL. Por eso el melanoma sale peor.
9. Elegir el checkpoint por el máximo de Dice mete más ruido en el FPV que la semilla (3,4 a 5,1 veces).
10. Etapa extendida: 825 estudios, 100 000 iteraciones, ensamble de 5 pliegues. Ensamble con TTA: Dice^{+} 0,754, FPV 9,2 mL en validación.
11. La prueba se abre una sola vez, con todo preregistrado en git antes.
12. Limitaciones: zona anonimizada excluida, 3 mm, un solo centro, métricas propias, HD95 pendiente.

1. Medicina nuclear y la imagen

PET. Tomografía por emisión de positrones. El paciente recibe un trazador radiactivo y el equipo mide desde dónde salen los fotones. Muestra función, no forma.

FDG. ^{18}F-fluorodesoxiglucosa, una glucosa marcada. Entra a la célula como glucosa pero queda atrapada. *Como si:* tinta que se queda donde más se come azúcar. Vida media del ^{18}F: 109,8 minutos.

Captación fisiológica. Consumo normal de FDG sin enfermedad: encéfalo, miocardio, riñones, vejiga e intestino. Es la fuente principal de falsos positivos.

Captación patológica no tumoral. Inflamación o infección. Capta como un tumor, pero autoPET la anota como fondo, porque la única etiqueta es lesión maligna FDG ávida.

CT. Tomografía computada. Mide cuánto atenúa cada tejido los rayos X. Da la anatomía.

HU (unidades Hounsfield). Escala del CT: agua 0, aire -1000, hueso sobre 400. *En el proyecto:* ventana de -200 a 300 HU, llevada a 0 a 1.

Bq/mL. Actividad: desintegraciones por segundo por mililitro. Es lo que guarda el PET antes de convertirlo.

SUV. Valor de captación estandarizado: actividad del vóxel dividida por la dosis inyectada por kilo de peso. SUV 1 es lo que tendría un vóxel si el trazador se repartiera parejo. *En el proyecto:* SUV normalizado por peso (SUVbw), con corrección de decaimiento.

Corrección de decaimiento. Ajustar la dosis por el tiempo que pasó entre la inyección y la adquisición, porque el ^{18}F pierde la mitad cada 109,8 minutos.

SUVmax. El vóxel más caliente de una lesión. Lo usa la clínica para seguimiento.

MTV. Volumen tumoral metabólico: los mililitros de lesión segmentada. Es el biomarcador que esta segmentación permitiría calcular de rutina.

Umbral SUV 2,5. Regla clásica: todo lo que supera 2,5 se considera sospechoso. *En el proyecto:* la referencia clásica.

Referencia interna, criterio de Deauville. Comparar una lesión con un órgano del mismo paciente (hígado, pool vascular) en lugar de un número fijo. *En el proyecto:* base del modelo E.

Atlas de captación normal. Valores de SUV de cada órgano en controles sanos. *En el proyecto:* 35 controles; hígado con mediana 2,19, que coincide con la literatura.

MIP. Proyección de intensidad máxima: la "radiografía" del PET, cada línea de vista muestra su valor más alto.

Desfase PET-CT. El PET se adquiere respirando y el CT en apnea, así que en el diafragma las dos imágenes no calzan. *En el proyecto:* medido en 200 estudios.

2. Formatos y geometría

DICOM. Formato estándar de imagen médica: un archivo por corte, con imagen y metadatos (peso, dosis, hora, posición).

Paciente, estudio, serie. Un paciente tiene estudios (cada visita al equipo) y cada estudio tiene series (PET, CT, segmentación).

NIfTI. Un solo archivo por volumen 3D con su geometría. Más cómodo para procesar que cientos de DICOM.

DICOM SEG. Objeto DICOM que guarda una segmentación. *En el proyecto:* tuve que corregir su orientación para que coincidiera con el PET.

Vóxel. El píxel en 3D. Tiene tamaño en mm en las tres direcciones.

Isotrópico. Mismo tamaño en las tres direcciones. *En el proyecto:* 3 mm por lado. El PET original es 2,04 × 2,04 × 3 mm.

Remuestreo. Recalcular la imagen en otra grilla de vóxeles, interpolando. *En el proyecto:* todo a 3 mm; el CT a la grilla del PET.

Sistema LPS. Ejes del paciente en DICOM: x a la izquierda, y hacia atrás, z hacia la cabeza.

Máscara binaria. Volumen de ceros y unos. 1 es lesión. Es lo que la red aprende a dibujar.

Anonimización (defacing). Borrar la cara y el cráneo para que no se pueda reconstruir el rostro. *En el proyecto:* ahí el SUV es 0, pero la anotación conserva lesiones: 3,7 % del volumen anotado. Excluyo esa zona al evaluar.

Métrica corregida y cruda. Corregida: sin la zona borrada. Cruda: con ella. Reporto las dos.

3. Datos y diseño del experimento

autoPET / FDG-PET-CT-Lesions. Colección pública de TCIA: 1 014 estudios de 900 pacientes de Tübingen. Pulmón, linfoma, melanoma y controles negativos. Licencia CC BY 4.0.

TCIA. The Cancer Imaging Archive, el repositorio público de donde descargué los datos.

Control negativo. Estudio sin lesión anotada. Sirve para medir falsos positivos puros.

Subconjunto de trabajo. 251 estudios: 67 por diagnóstico y 50 controles, sorteados con semilla 423.

Entrenamiento, validación, prueba. Entrenamiento: la red

aprende. Validación: comparo y decido. Prueba: la nota final, se mira una sola vez. *Como si:* ensayos, simulacro y examen.

Partición por paciente. Ningún paciente aparece en dos grupos. Si apareciera, la red "reconocería" al paciente.

Estratificación. Sortear respetando las proporciones de cada diagnóstico en cada grupo.

Fuga de datos (data leakage). Que información de validación o prueba se cuele al entrenamiento. *En el proyecto:* auditada el 6 de septiembre: sin fugas.

Semilla. Número que fija el azar. Misma semilla, mismo resultado. *En el proyecto:* 423, 2 y 3. Tres semillas por brazo para separar el efecto de la arquitectura del azar.

Brazo. Cada variante que se compara: A, B, C, E y la clásica.

Protocolo congelado. Toda la configuración fijada antes de comparar. La única variable que cambia es la arquitectura.

Hipótesis. Lo que espero y puedo refutar: la atención cruzada baja el FPV sin subir el FNV.

Criterio de éxito previo. Número que fijo antes de correr para declarar si algo funcionó. Evita acomodar la conclusión al resultado.

Preregistro. Dejar escritas las hipótesis, el sistema final y los criterios antes de abrir la prueba, en un commit. *En el proyecto:* con candado: el script se niega a correr si esos archivos cambiaron sin registrar.

Conjunto de selección. Datos que usé para elegir. Lo que mido ahí sale algo optimista. *En el proyecto:* los 12 estudios de la validación rápida están dentro de los 26.

4. Procesamiento clásico

Umbralización. Encender los vóxeles que superan un valor.

Erosión y dilatación. Erosión achica las regiones encendidas; dilatación las agranda. Se hacen con un elemento estructurante (una pequeña esfera o cubo).

Apertura morfológica. Erosión y luego dilatación. Borra puntos sueltos y puentes finos sin cambiar mucho lo grande. *En el proyecto:* radio 1.

Componente conexa. Grupo de vóxeles encendidos que se tocan. *En el proyecto:* 26-conectividad: se tocan por cara, arista o vértice. Cada componente es una lesión.

Tamaño mínimo. Descartar componentes menores a un volumen. *En el proyecto:* 0,5 mL.

Exclusión anatómica. Apagar lo que cae en órganos de captación normal.

TotalSegmentator. Red ya entrenada que segmenta más de cien estructuras en el CT. *En el proyecto:* para el reparto del falso positivo por órgano, la exclusión y la referencia hepática. Nunca como entrada de A, B o C.

Máscara corporal. Todo lo que no es aire en el CT. *En el proyecto:* recorte a la caja del cuerpo.

5. Redes neuronales

Red convolucional. Red que aplica filtros pequeños que se deslizan por la imagen y aprenden qué patrones buscar.

U-Net 3D. Red en forma de U. El codificador baja la resolución y aprende qué hay; el decodificador la sube y dibuja dónde está; las conexiones de salto llevan el detalle fino de un lado al otro. *En el proyecto:* MONAI, canales 32, 64, 128, 256, 320.

Codificador y decodificador. Bajada que resume y subida que reconstruye.

Conexión de salto (skip). Atajo que copia los mapas del codificador al decodificador del mismo nivel para no perder bordes.

Cuello de botella. El nivel más profundo de la U, con la menor resolución. *En el proyecto:* parche de 96^3, cuatro reducciones, cubo de $6^3 = 216$ posiciones.

Canal. Cada volumen que entra apilado a la red. *En el proyecto:* A: SUV y CT. E: SUV, CT y SUV/hígado.

Parámetros. Los números que la red aprende. *En el proyecto:* A 12,9 M; A+ 24,3 M; B 24,0 M; C 24,4 M.

GFLOP. Miles de millones de operaciones por parche. Mide el costo. *En el proyecto:* A 37, B y C 59.

Normalización de instancia. Llevar cada mapa a media 0 y desviación 1 dentro de cada imagen. Efecto lateral: borra cualquier señal que sea constante en el espacio. *En el proyecto:* por eso murió la atención de C.

Softmax y logits. La red da dos números por vóxel (fondo y lesión); softmax los convierte en probabilidades que suman 1.

Fusión temprana. PET y CT entran juntos como canales desde la primera capa. *En el proyecto:* modelo A. *Como si:* leer las dos imágenes superpuestas en una sola lámina.

Fusión intermedia. Cada modalidad tiene su propio codificador y se juntan más adentro. *En el proyecto:* B y C.

Codificador dual. Dos caminos de bajada independientes, uno por modalidad.

Concatenación. Apilar los mapas de las dos ramas uno sobre otro y dejar que la capa siguiente los mezcle. *En el proyecto:* modelo B, $320 + 320 = 640$ canales.

Atención (consulta, clave, valor). Cada posición hace una pregunta (consulta), cada posición ofrece una etiqueta (clave) y un contenido (valor). La respuesta mezcla los valores según cuánto calza la pregunta con cada etiqueta.

Atención cruzada. La consulta sale de una modalidad y las claves y valores de la otra. *En el proyecto:* C: el PET pregunta, el CT responde. *Como si:* el residente que ve una mancha caliente y mira el CT para saber qué órgano es.

Factor de mezcla γ. Número aprendido que multiplica la salida de la atención antes de sumarla. Si es 0, la atención no aporta. *En el proyecto:* con inicio 0 quedó en 0,0125; con inicio 1, entre 0,985 y 1,005.

Control de capacidad. Modelo con el mismo tamaño pero sin el mecanismo que se prueba. *En el proyecto:* B es el control de C; A+ es A con 1,375 veces los canales.

Ablación. Quitar una pieza a un modelo ya entrenado y volver a medir. *En el proyecto:* C con $\gamma = 0$: diferencia 0,000. E sin referencia hepática: cambian 23 de 26 predicciones, efecto neto 1,4 mL.

6. Entrenamiento

Parche 3D. Cubo recortado del estudio que la red ve de una vez. *En el proyecto:* 96^3 vóxeles, 288 mm de lado.

Muestreo sesgado. Elegir más parches centrados en lesión de los que saldrían al azar. *En el proyecto:* 70 %.

Lote (batch). Parches que se procesan juntos antes de actualizar. *En el proyecto:* 2.

Iteración y época. Iteración: un lote y una actualización. Época: pasar una vez por todos los datos. *En el proyecto:* 25 000 iteraciones en la etapa 1; 100 000 en la extendida.

Función de pérdida. El número que la red intenta bajar. *En el proyecto:* Dice más entropía cruzada: Dice cuida el solapamiento global, la entropía cruzada cuida cada vóxel.

Gradiente. Dirección en que hay que mover cada peso para bajar la pérdida.

Optimizador AdamW. Algoritmo que mueve los pesos usando los gradientes, con un freno suave a los pesos grandes. *En el proyecto:* tasa $3 \cdot 10^{-4}$.

Tasa de aprendizaje y programa polinomial. Tamaño del pa-

so, que se achica hasta 0 al final (potencia 0,9).

Recorte de gradiente. Limitar el tamaño del gradiente para que un lote raro no desarme lo aprendido. *En el proyecto:* norma 12.

Aumento de datos. Cambios al azar en cada parche para que no memorice. *En el proyecto:* solo volteos laterales y anteroposteriores, nunca en el eje cabeza a pies.

Sobreajuste. Aprenderse los ejemplos en vez de la regla. Se nota cuando entrenamiento mejora y validación no.

Checkpoint. Foto de la red guardada a mitad del entrenamiento. *En el proyecto:* `mejor.pt`: el de mejor Dice en la validación rápida. `ultimo.pt`: el final.

Validación rápida. Medir unos pocos estudios cada 1 000 iteraciones para elegir checkpoint. *En el proyecto:* 12 estudios fijos; criterio ruidoso.

mps, fp32. mps: el acelerador gráfico de los Mac con chip M. fp32: precisión simple. *En el proyecto:* Mac de 24 GB, entre 5 y 6,5 horas por corrida de 25 000 iteraciones.

PyTorch y MONAI. PyTorch: la librería de redes. MONAI: la capa médica sobre PyTorch (transformaciones 3D, U-Net, ventana deslizante).

7. Inferencia

Ventana deslizante. Recorrer el estudio completo con cubos del tamaño del parche, solapados, y promediar. *En el proyecto:* solape 0,5 con ponderación gaussiana: el centro del cubo pesa más que el borde.

Umbral de probabilidad. Desde qué probabilidad un vóxel se declara lesión. *En el proyecto:* 0,5 por defecto; 0,6 en el sistema final, decidido con los datos fuera de pliegue.

TTA. Aumento en inferencia: predecir también la imagen volteada, devolverla y promediar.

Ensamble. Promediar varias redes. *Como si:* pedir la opinión de varios residentes y quedarse con el consenso. *En el proyecto:* voto de 3 semillas de A: Dice^{+} 0,662. Ensamble de 5 pliegues con TTA: 0,754.

Regla del hígado. Borrar islas cuyo SUVmax no llega al doble de la referencia hepática. *En el proyecto:* probada y no adoptada: quitaba 22 % de marcas falsas pero perdía 6,4 % de lesiones.

8. Métricas

Verdadero y falso positivo, falso negativo. VP: marqué y era lesión. FP: marqué y no era. FN: no marqué y era.

Dice. $2|A \cap B|/(|A| + |B|)$: solapamiento entre predicción y verdad, de 0 a 1.

Dice^{+}. Dice promediado solo en estudios positivos, porque en un control el Dice no está definido.

FPV. Volumen de falso positivo: mL de islas predichas que no tocan ninguna lesión real.

FNV. Volumen de falso negativo: mL de lesiones reales que la predicción no toca.

Detección por lesión. Fracción de lesiones (componentes de la verdad) que la predicción toca. *En el proyecto:* 256 lesiones en validación; prácticamente todas sobre 10 mL, 22 % bajo 1 mL.

Marcas falsas por estudio. Cuántas islas falsas tiene que borrar el médico. *En el proyecto:* 4,8 a 5,8 en un modelo, 2,8 en el ensamble.

Carga de corrección. mL a borrar más mL a agregar, contra dibujar todo desde cero. *En el proyecto:* A ahorra 57 %.

FP por órgano. El FPV repartido según dónde cae, con los mapas de TotalSegmentator. *En el proyecto:* clásica: 74 % en órganos fisiológicos.

Hausdorff 95. Distancia entre bordes de predicción y verdad, en el percentil 95. Mide qué tan lejos queda el peor borde razonable. *En el proyecto:* comprometido, pendiente.

Bland-Altman. Gráfico de la diferencia entre dos mediciones contra su promedio. Sesgo: la diferencia media. Límites de concordancia: sesgo $\pm$ 1,96 desviaciones. *En el proyecto:* MTV: sesgo $-30{,}2$ mL, límites $-244{,}5$ a $+184{,}1$.

9. Estadística

Media $\pm$ desviación. Promedio y cuánto varía. *En el proyecto:* entre las tres semillas.

Intervalo de confianza 95 %. Rango donde razonablemente está el valor real. Si una diferencia tiene un IC que cruza el 0, no puedo decir que exista.

Bootstrap. Remuestrear con reposición los estudios miles de veces para ver cuánto varía un resultado.

Comparación pareada. Comparar dos brazos estudio por estudio, sobre los mismos pacientes. Quita la variación entre pacientes.

Wilcoxon. Prueba no paramétrica para diferencias pareadas. No supone distribución normal.

Valor p. Probabilidad de ver una diferencia así si en realidad no hubiera ninguna. *En el proyecto:* 0,52, 0,87 y 0,93 contra A.

Empate. No es que sean iguales: con estos datos no se puede distinguir una diferencia.

Potencia. Capacidad de detectar una diferencia que sí existe. Con 20 positivos en validación es baja; por eso la prueba (39 positivos) y la etapa extendida.

10. Etapa extendida (rama `extendido`)

Validación cruzada en 5 pliegues. Dividir los datos en 5 partes; entrenar 5 redes, cada una dejando fuera una parte distinta.

Fuera de pliegue (OOF). Predicción de cada estudio hecha por la red que no lo vio. *En el proyecto:* 825 estudios, Dice^{+} 0,689. Permite decidir umbrales sin tocar la prueba.

Preentrenamiento anatómico. Enseñarle primero al codificador del CT a segmentar órganos y después usarlo en la tarea. *En el proyecto:* B_pre 0,707 contra B 0,705: no ayudó.

Pérdida ponderada por órgano. Castigar más los falsos positivos en órganos fisiológicos. *En el proyecto:* probada; no cumplió su criterio.

H1 y H2. H1: la hipótesis original sobre las arquitecturas. H2: el sistema final (ensamble con TTA a umbral 0,6) frente al mejor modelo individual.

11. Herramientas de trabajo

Git, commit, rama, etiqueta. Git guarda la historia del código. Commit: una foto fechada. Rama: una línea de trabajo paralela. Etiqueta: un nombre fijo para una foto. *En el proyecto:* `main` cerrada con la etiqueta `resultados-validacion-4-brazos`; `extendido` continúa.

GitHub. Servidor donde vive el repositorio público.

Bitácora. Diario fechado del proyecto: qué hice, por qué, qué decidí.

Pruebas unitarias. Pequeños programas que verifican que cada función hace lo que dice, por ejemplo con fantomas sintéticos.

Entorno virtual. Carpeta con su propia copia de Python y librerías, para que el proyecto no dependa del resto del computador.

YAML de configuración. Archivo donde están todos los números del experimento en un solo lugar.

LaTeX. Sistema para escribir documentos técnicos. El informe final va en `report/`.