

Segmentación automática de lesiones hipermetabólicas en FDG-PET/CT de cuerpo completo: fusión temprana frente a fusión intermedia con atención cruzada guiada por la anatomía

Integrante: Sebastián Inostroza — Tecnólogo Médico; estudiante del Doctorado en Ingeniería y Ciencias de la Salud, Universidad de Valparaíso. **Modalidad:** individual.

1. Descripción del problema

La tomografía por emisión de positrones con ^{18}F -FDG combinada con tomografía computada (PET/CT) es el examen de referencia para estadificar y controlar linfoma, melanoma y cáncer de pulmón: el PET muestra el metabolismo glucolítico aumentado de las lesiones (efecto Warburg) y el CT aporta la anatomía. La segmentación de las lesiones es el paso previo a biomarcadores cuantitativos como el volumen tumoral metabólico (MTV) y el SUVmax, hoy delineados a mano o con umbrales. El obstáculo central es la captación fisiológica: encéfalo, miocardio, riñones y vías urinarias, grasa parda e inflamación superan con holgura el umbral clásico $\text{SUV} \geq 2,5$, y una red que mira solo el PET, o que mezcla PET y CT desde la primera capa (fusión temprana), tiende a marcar esos órganos como tumor. Cada mililitro de falso positivo infla el MTV y degrada el seguimiento del paciente.

El reto autoPET fija el estado del arte sobre datos públicos. En su edición 2022, todas las soluciones ganadoras fueron U-Net 3D del tipo nnU-Net; el primer lugar obtuvo Dice 0,623, volumen falso negativo (FNV) 0,54 mL y volumen falso positivo (FPV) 2,84 mL, promediados sobre estudios positivos y negativos [2]. Un nnU-Net sin modificar alcanza Dice 0,69 con FPV 5,78 mL y FNV 6,27 mL en un conjunto interno [4], y bajo cambio de centro (autoPET-II) el mejor Dice cae a 0,36 [2]. Esas soluciones se entrenaron con 8 GPU A100 durante 5–7 días por configuración [3]. En cohortes distintas de autoPET, la fusión intermedia con atención ha mostrado ganancias sobre la concatenación: un módulo de atención espacial PET→CT en pulmón [5], atención cruzada multiescala en linfoma (DSC 0,751) [6] y un transformer de atención cruzada en nasofaringe [7]. Sin embargo, no está publicada, sobre autoPET y con presupuesto de entrenamiento idéntico, la comparación entre fusión temprana, fusión intermedia por concatenación y fusión intermedia con atención cruzada, ni el análisis de en qué órganos fisiológicos se concentran los falsos positivos de cada una. Ese es el vacío que aborda este proyecto.

2. Objetivos del trabajo

Objetivo general. Implementar y comparar, con el mismo presupuesto de datos e iteraciones, tres estrategias de fusión PET/CT en una U-Net 3D para segmentar lesiones hipermetabólicas en FDG-PET/CT de cuerpo completo, y cuantificar su efecto sobre los falsos positivos en órganos de captación fisiológica y sobre los biomarcadores MTV y SUVmax. **Hipótesis:** condicionar las activaciones funcionales (PET) a la evidencia anatómica (CT) mediante atención cruzada reduce el FPV respecto de la fusión temprana sin aumentar el FNV.

Objetivos específicos

- **OE1 — Pipeline de preprocesamiento y referencia clásica.** Conversión DICOM→NIfTI con cálculo de SUV normalizado por peso, remuestreo isotrópico a 3 mm, ventaneo de tejido blando (–200 a 300 HU) y normalización, recorte del cuerpo y extracción de parches 3D de 96^3 vóxeles con muestreo sesgado a lesiones. Como referencia de partida se evalúa con las mismas métricas un método clásico del curso: umbral $\text{SUV} \geq 2,5$, apertura y cierre morfológico y exclusión anatómica de órganos fisiológicos.
- **OE2 — Modelo A, fusión temprana.** U-Net 3D de dos canales de entrada (SUV, CT) en MONAI, pérdida Dice + entropía cruzada, precisión mixta.
- **OE3 — Modelos B y C, fusión intermedia.** Dos codificadores independientes (PET y CT) y un decodificador común. En B las representaciones se concatenan en el cuello de botella (control); en C se combinan mediante atención cruzada, donde el mapa PET actúa como consulta y el mapa CT como clave y valor, de modo que la sospecha metabólica se module por la anatomía. B permite atribuir cualquier diferencia entre A y C al mecanismo de atención y no a la duplicación del codificador.
- **OE4 — Evaluación comparativa.** Dice, distancia de Hausdorff al percentil 95, FPV y FNV por estudio con el script oficial de autoPET; FPV desglosado por órgano (encéfalo, miocardio, riñones y vejiga, hígado, grasa parda) mediante máscaras anatómicas derivadas del CT; error absoluto en MTV y SUVmax por paciente; intervalos de confianza por bootstrap sobre el conjunto de prueba y análisis cualitativo de casos.

3. Punto de partida

El proyecto se construye sobre código abierto existente y añade una implementación propia acotada. **Base:** MONAI (transformaciones 3D, arquitecturas UNet/DynUNet, inferencia por ventana deslizante, métricas) [8]; el repositorio oficial del reto [lab-midas/autoPET](https://lab-midas.github.io/autoPET/), que aporta la conversión de los DICOM de TCIA a NIfTI con cálculo de SUV, un baseline nnU-Net y el script de evaluación con Dice, FPV y FNV; la documentación de nnU-Net para dimensionar el modelo (la configuración estándar requiere ≈ 10 GB de VRAM) [3]; y los diseños de fusión de Fu et al. [5] y Huang et al. [6] como referencia arquitectónica. **Implementación propia:** el codificador dual, el bloque de atención cruzada sobre los tokens del cuello de botella (con parches de 96^3 y cuatro reducciones, $6^3 = 216$ posiciones, por lo que la atención es barata), el muestreo de parches, la referencia clásica y el análisis de falsos positivos por órgano. **Recursos:** preprocesamiento y análisis en computador personal (CPU); entrenamiento en Google Colab Pro (GPU T4/L4, 16–24 GB) con puntos de control en Google Drive; presupuesto de $\approx 25\,000$ iteraciones por modelo, del orden de 10–15 h de GPU cada uno. **Alcance:** subconjunto de 250 estudios con partición por paciente 70/10/20; resolución de 3 mm en lugar de los 2 mm habituales, limitación que se declara y que es compatible con lesiones FDG clínicamente relevantes (> 1 cm).

4. Datasets

FDG-PET-CT-Lesions (autoPET), The Cancer Imaging Archive. 900 pacientes y 1 014 estudios PET/CT de cuerpo completo del Hospital Universitario de Tübingen: 501 estudios positivos (168 cáncer de pulmón, 145 linfoma, 188 melanoma) y 513 controles negativos; PET con vóxel de $2,04 \times 2,04 \times 3$ mm; máscaras 3D de todas las lesiones FDG-ávidas malignas, delineadas manualmente por un lector experto y revisadas por consenso [1]. Licencia CC BY 4.0 para la versión con rostro anonimizado y los datos clínicos. DOI 10.7937/gkr0-xv29. cancerimagingarchive.net/collection/fdg-pet-ct-lesions/. El reto distribuye además los mismos estudios ya convertidos a NIfTI (SUV.nii.gz, CTres.nii.gz remuestreado a la grilla del PET, SEG.nii.gz): autopet-ii.grand-challenge.org/dataset/.

Subconjunto de trabajo. 200 estudios positivos estratificados por diagnóstico y 50 negativos, seleccionados de forma reproducible (semilla fija) y descargados por paciente desde TCIA. La colección hermana PSMA-PET-CT-Lesions (597 estudios, CC BY 4.0) se reserva como trabajo futuro para evaluar generalización entre trazadores.

5. Artículos relacionados

[1] Gatidis S, Hepp T, Früh M, et al. A whole-body FDG-PET/CT Dataset with manually annotated Tumor Lesions. Sci Data. 2022;9:601. doi:10.1038/s41597-022-01718-3

[2] Gatidis S, Früh M, Fabritius MP, et al. Results from the autoPET challenge on fully automated lesion segmentation in oncologic PET/CT imaging. Nat Mach Intell. 2024;6:1396–1405. doi:10.1038/s42256-024-00912-9

[3] Isensee F, Maier-Hein KH. Look Ma, no code: fine tuning nnU-Net for the AutoPET II challenge by only adjusting its JSON plans. arXiv:2309.13747; 2023. Documentación: github.com/MIC-DKFZ/nnUNet

[4] Alloula A, McGowan DR, Papież BW. Autopet Challenge 2023: nnUNet-based whole-body 3D PET-CT tumour segmentation. arXiv:2309.13675; 2023.

[5] Fu X, Bi L, Kumar A, Fulham M, Kim J. Multimodal Spatial Attention Module for Targeting Multimodal PET-CT Lung Tumor Segmentation. IEEE J Biomed Health Inform. 2021;25(9):3507–3516. doi:10.1109/JBHI.2021.3059453

[6] Huang H, Qiu L, Yang S, et al. 3D lymphoma segmentation on PET/CT images via multi-scale information fusion with cross-attention. Med Phys. 2025. doi:10.1002/mp.17763

[7] Zhao W, Huang Z, Tang S, et al. MMCA-NET: A Multimodal Cross Attention Transformer Network for Nasopharyngeal Carcinoma Tumor Segmentation Based on a Total-Body PET/CT System. IEEE J Biomed Health Inform. 2024. doi:10.1109/JBHI.2024.3405993

[8] Cardoso MJ, et al. MONAI: An open-source framework for deep learning in healthcare. arXiv:2211.02701; 2022.

[9] Isensee F, Jaeger PF, Kohl SAA, Petersen J, Maier-Hein KH. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nat Methods. 2021;18:203–211. doi:10.1038/s41592-020-01008-z

[10] Oktay O, et al. Attention U-Net: Learning Where to Look for the Pancreas. MIDL 2018. arXiv:1804.03999